

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG



BÁO CÁO BÀI TẬP LỚN

HỌC PHẦN: NHẬP MÔN KHOA HỌC DỮ LIỆU

**ĐỀ TÀI: XÂY DỰNG HỆ THỐNG GỢI Ý PHIM
THÔNG MINH**

Nhóm Lớp: 06

Sinh viên thực hiện:

Trần Hữu Phúc B22DCCN634

Giảng viên hướng dẫn: TS. Trần Tiến Công

HÀ NỘI - 2025

MỤC LỤC

1. GIỚI THIỆU	2
2. THU THẬP DỮ LIỆU.....	2
2.1. Nguồn dữ liệu.....	2
2.2. Cấu trúc dữ liệu.....	2
2.3. Quy mô dữ liệu	2
3. LÀM SẠCH VÀ CHUẨN BỊ DỮ LIỆU	3
3.1. Làm sạch dữ liệu phim.....	3
3.2. Làm sạch dữ liệu đánh giá	3
4. PHÂN TÍCH VÀ TRỰC QUAN HÓA DỮ LIỆU	4
4.1. Phân bố đánh giá.....	4
4.2. Hoạt động người dùng	4
4.3. Độ phổ biến của phim.....	4
4.4. Độ thưa của ma trận	4
5. XÂY DỰNG MÔ HÌNH GỢI Ý.....	5
5.1. User-Based Collaborative Filtering	5
5.2. Item-Based Collaborative Filtering	6
5.3. Neural Collaborative Filtering (NCF)	7
5.4. Hybrid Weighted Model	8
5.5. FAISS Semantic Search.....	9
5.6. Chia dữ liệu train/test.....	10
6. ĐÁNH GIÁ MÔ HÌNH	10
6.1. Các phương pháp đánh giá.....	10
6.2. Kết quả đánh giá	11

1. GIỚI THIỆU

Hệ thống kết hợp nhiều phương pháp học máy bao gồm Lọc cộng tác dựa trên người dùng (User-Based Collaborative Filtering), Lọc cộng tác dựa trên mục (Item-Based Collaborative Filtering), Lọc cộng tác thần kinh (Neural Collaborative Filtering), mô hình Hybrid, và tìm kiếm ngữ nghĩa vector sử dụng FAISS. Dữ liệu được thu thập từ Kaggle với quy mô 3 triệu đánh giá và hơn 16,000 phim, sau đó được làm sạch và chuẩn bị kỹ lưỡng trước khi huấn luyện các mô hình.

2. THU THẬP DỮ LIỆU

2.1. Nguồn dữ liệu

Hệ thống sử dụng bộ dữ liệu Anime Recommendation Database 2020 được công bố trên Kaggle bởi tác giả hernan4444. Đây là một trong những bộ dữ liệu về phim phổ biến nhất, cung cấp thông tin phong phú về cả phim và hành vi đánh giá của người dùng.

2.2. Cấu trúc dữ liệu

Bộ dữ liệu bao gồm hai thành phần chính:

- Dữ liệu Phim (anime_with_synopsis.csv):
 - + MAL_ID: Mã định danh duy nhất của phim trên MyAnimeList
 - + Name: Tên phim
 - + Score: Điểm đánh giá trung bình
 - + Genres: Thể loại (Action, Comedy, Drama, v.v.)
 - + Synopsis: Mô tả nội dung
- Dữ liệu Đánh giá (rating_complete.csv):
 - + user_id: Mã định danh người dùng
 - + anime_id: Mã định danh phim
 - + rating: Điểm đánh giá (thang 1-10)

2.3. Quy mô dữ liệu

Thống kê	Giá trị
Tổng số ratings	3,000,000

Tổng số phim	16,214
Số người dùng duy nhất	16,131
Số phim được đánh giá	14,636
Khoảng rating	[1, 10]
Rating trung bình	7.51

3. LÀM SẠCH VÀ CHUẨN BỊ DỮ LIỆU

3.1. Làm sạch dữ liệu phim

Quá trình làm sạch dữ liệu phim bao gồm:

- Chuẩn hóa tên cột: Chuyển đổi từ các tên cột trong dataset gốc (MAL_ID, Name, Score, Genres) sang định dạng chuẩn (mal_id, name, score, genres)
- Xử lý dữ liệu thiếu: Điền giá trị rỗng cho các trường synopsis và genres bị thiếu
- Chuyển đổi kiểu dữ liệu: Chuyển score về dạng số thực, xử lý các giá trị NaN bằng 0
- Loại bỏ bản ghi trùng lặp: Xóa các bản ghi trùng lặp dựa trên mal_id
- Loại bỏ dữ liệu không hợp lệ: Xóa các bản ghi thiếu các trường quan trọng (mal_id, name)

3.2. Làm sạch dữ liệu đánh giá

Quá trình làm sạch dữ liệu đánh giá bao gồm:

- Loại bỏ đánh giá không hợp lệ: Xóa các đánh giá có giá trị -1 (đại diện cho "chưa xem")
- Lọc phạm vi hợp lệ: Chỉ giữ lại các đánh giá trong khoảng [1, 10]
- Loại bỏ trùng lặp: Xóa các cặp (user_id, anime_id) trùng lặp, giữ bản ghi đầu tiên
- Chuẩn hóa kiểu dữ liệu: Chuyển đổi user_id, anime_id, rating về dạng số nguyên

4. PHÂN TÍCH VÀ TRỰC QUAN HÓA DỮ LIỆU

4.1. Phân bố đánh giá

Phân tích phân bố đánh giá cho thấy xu hướng đánh giá thiên về điểm cao:

- Điểm trung bình: 7.51
- Trung vị: 8.00
- Độ lệch chuẩn: 1.69

Phân bố này cho thấy người dùng có xu hướng đánh giá cao các phim họ xem, điều này phù hợp với hành vi thực tế khi người dùng thường chỉ hoàn thành và đánh giá những bộ phim họ thực sự thích.

4.2. Hoạt động người dùng

Phân tích số lượng đánh giá trên mỗi người dùng:

- Trung bình: 186 đánh giá/người dùng
- Trung vị: 112 đánh giá/người dùng
- Tối đa: 8,215 đánh giá/người dùng

Sự chênh lệch lớn giữa trung bình và trung vị cho thấy phân bố lệch phải, với một số ít người dùng rất tích cực.

4.3. Độ phổ biến của phim

Phân tích số lượng đánh giá trên mỗi phim:

- Trung bình: 205 đánh giá/phim
- Trung vị: 22 đánh giá/phim
- Tối đa: 9,567 đánh giá/phim

Phân bố này tuân theo quy luật đuôi dài (long-tail distribution), với một số ít phim rất phổ biến và đa số có ít đánh giá.

4.4. Độ thưa của ma trận

Ma trận user-item có độ thưa rất cao (>99%), đây là thách thức phổ biến trong các hệ thống gợi ý. Độ thưa này ảnh hưởng trực tiếp đến hiệu suất của các phương pháp Collaborative Filtering truyền thống.

5. XÂY DỰNG MÔ HÌNH GỢI Ý

5.1. User-Based Collaborative Filtering

Phương pháp User-Based CF dựa trên giả định rằng những người dùng có sở thích tương đồng trong quá khứ sẽ tiếp tục có sở thích tương đồng trong tương lai. Thuật toán tìm K người dùng "hàng xóm" gần nhất (K-Nearest Neighbors) dựa trên độ tương đồng và sử dụng đánh giá của họ để dự đoán.

Cosine Similarity:

$$\text{sim}(u, v) = \frac{\sum_{i \in I_{uv}} r_{u,i} \cdot r_{v,i}}{\sqrt{\sum_{i \in I_{uv}} r_{u,i}^2} \cdot \sqrt{\sum_{i \in I_{uv}} r_{v,i}^2}}$$

Pearson Correlation:

$$\text{sim}(u, v) = \frac{\sum_{i \in I_{uv}} (r_{u,i} - \bar{r}_u) \cdot (r_{v,i} - \bar{r}_v)}{\sqrt{\sum_{i \in I_{uv}} (r_{u,i} - \bar{r}_u)^2} \cdot \sqrt{\sum_{i \in I_{uv}} (r_{v,i} - \bar{r}_v)^2}}$$

Trong đó:

- $r_{u,i}$ là đánh giá của người dùng u cho item i
- $\bar{r}_u$ là điểm trung bình của người dùng u
- I_{uv} là tập các item được cả u và v đánh giá

Điểm dự đoán cho cặp (người dùng u , phim i) được tính bằng trung bình có trọng số:

$$\hat{r}_{u,i} = \frac{\sum_{j \in N_k(i)} \text{sim}(i, j) \cdot r_{u,j}}{\sum_{j \in N_k(i)} |\text{sim}(i, j)|}$$

Trong đó $N_k(i)$ là tập K item tương đồng nhất với i mà người dùng u đã đánh giá.

Cấu hình mô hình:

Tham số	Giá trị	Mô tả
k_neighbors	50	Số hàng xóm xem xét
similarity	cosine	Phương pháp tính tương đồng
min_overlap	3	Số item tối thiểu cùng đánh giá

Để tăng tốc độ gợi ý, hệ thống sử dụng phương pháp vectorized prediction thay vì tính toán tuần tự từng item. Ma trận user-item được lưu dưới dạng sparse matrix (CSR format) để tiết kiệm bộ nhớ.

5.2. Item-Based Collaborative Filtering

Khác với User-Based CF, phương pháp Item-Based CF tập trung vào mối quan hệ giữa các item. Giả định cơ bản là nếu một người dùng thích item A và item B tương tự item A, thì họ cũng sẽ thích item B.

Để xử lý vấn đề khác biệt trong thang đánh giá của người dùng (một số người thường cho điểm cao, một số khác thường cho điểm thấp), hệ thống sử dụng Adjusted Cosine Similarity:

$$sim(i, j) = \frac{\sum_{u \in U_{ij}} (r_{u,i} - \bar{r}_u) \cdot (r_{u,j} - \bar{r}_u)}{\sqrt{\sum_{u \in U_{ij}} (r_{u,i} - \bar{r}_u)^2} \cdot \sqrt{\sum_{u \in U_{ij}} (r_{u,j} - \bar{r}_u)^2}}$$

Trong đó U_{ij} là tập người dùng đã đánh giá cả item i và j .

Phương pháp này chuẩn hóa đánh giá của mỗi người dùng theo điểm trung bình của họ trước khi tính toán, giúp loại bỏ bias trong đánh giá.

Điểm dự đoán được tính theo công thức:

$$\hat{r}_{u,i} = \frac{\sum_{j \in N_k(i)} sim(i, j) \cdot r_{u,j}}{\sum_{j \in N_k(i)} |sim(i, j)|}$$

Trong đó $N_k(i)$ là tập K item tương đồng nhất với i mà người dùng u đã đánh giá.

Cấu hình mô hình:

Tham số	Giá trị	Mô tả
k_similar	30	Số item tương đồng xem xét
similarity	adjusted_cosine	Phương pháp tính tương đồng
min_ratings	100	Số đánh giá tối thiểu để được gợi ý

Ưu điểm so với User-Based

- Ổn định hơn: Mỗi quan hệ giữa các item thường ổn định hơn so với giữa người dùng
- Khả năng mở rộng tốt hơn: Trong nhiều hệ thống, số lượng item ít hơn số người dùng
- Giải thích dễ dàng hơn: "Bạn thích A, B tương tự A, nên gợi ý B"

5.3. Neural Collaborative Filtering (NCF)

Neural Collaborative Filtering sử dụng mạng neural để học các biểu diễn ẩn (latent representations) của người dùng và item. Kiến trúc kết hợp hai thành phần: Generalized Matrix Factorization (GMF) và Multi-Layer Perceptron (MLP).

Thành phần GMF, học tương tác tuyến tính giữa người dùng và item:

$$h_{GMF} = P_u^{GMF} \odot q_i^{GMF}$$

Trong đó $\odot$ là phép nhân element-wise, P_u^{GMF} và q_i^{GMF} là embedding của người dùng và item.

Thành phần MLP, học tương tác phi tuyến thông qua các lớp ẩn:

$$z_0 = [p_u^{MLP}, q_i^{MLP}]$$

$$z_l = \text{ReLU}(\text{BN}(W_l z_{l-1} + b_l))$$

Lớp kết hợp và dự đoán:

$$\hat{r}_{ui} = \sigma(h^T[h_{GMF}, h_{MLP}])$$

Cấu hình mạng:

Thành phần	Cấu hình
GMF Embedding	64 chiều
MLP Layers	[128, 64, 32]
Dropout	0.2
Batch Normalization	Áp dụng sau mỗi lớp
Optimizer	Adam

Learning Rate	0.001
Batch Size	256
Max Epochs	30
Early Stopping	5 epochs

Các embedding được khởi tạo từ phân phối chuẩn với độ lệch chuẩn 0.01. Các lớp Linear được khởi tạo bằng phương pháp Xavier Uniform để đảm bảo gradient không vanishing hoặc exploding.

Hệ thống sử dụng Mean Squared Error (MSE) làm hàm mất mát:

$$\mathcal{L} = \frac{1}{N} \sum_{(u,i) \in D} (r_{ui} - \hat{r}_{ui})^2$$

Do NCF yêu cầu ID liên tục từ 0, hệ thống xây dựng các bảng ánh xạ:

- user_id_map: user_id gốc $\rightarrow$ index liên tục
- item_id_map: anime_id gốc $\rightarrow$ index liên tục

Các ánh xạ này được lưu cùng mô hình để đảm bảo dự đoán chính xác.

5.4. Hybrid Weighted Model

Mô hình Hybrid kết hợp dự đoán từ nhiều mô hình cơ sở thông qua trọng số có thể điều chỉnh. Mục tiêu là tận dụng ưu điểm của từng phương pháp và bù đắp nhược điểm của nhau.

Dự đoán cuối cùng được tính theo công thức:

$$\hat{r}_{hybrid} = \alpha \cdot \hat{r}_{user} + \beta \cdot \hat{r}_{item}$$

Trong đó $\alpha + \beta = 1$ và các trọng số được chuẩn hóa tự động.

Hệ thống xử lý các trường hợp khi một hoặc cả hai mô hình không thể đưa ra dự đoán:

- Cả hai mô hình dự đoán được: Sử dụng trung bình có trọng số
- Chỉ User-Based dự đoán được: Sử dụng dự đoán từ User-Based
- Chỉ Item-Based dự đoán được: Sử dụng dự đoán từ Item-Based
- Không mô hình nào dự đoán được: Trả về 0

Trọng số tối ưu được tìm bằng Grid Search trên validation set:

$$\alpha^* = \arg \min_{\alpha \in 0, 0.1, \dots, 1.0} RMSE(\alpha)$$

Quá trình này thử 11 giá trị α khác nhau (0.0, 0.1, 0.2, ..., 1.0) và chọn cấu hình cho RMSE thấp nhất trên 1000 mẫu validation.

5.5. FAISS Semantic Search

Khác với các phương pháp Collaborative Filtering, FAISS Semantic Search sử dụng nội dung (content) của phim để tìm kiếm. Mỗi phim được biểu diễn bằng một vector embedding, và phim tương tự được tìm bằng K-Nearest Neighbors trong không gian vector.

Embedding được sinh bởi mô hình Sentence Transformers với kiến trúc paraphrase-multilingual-MiniLM-L12-v2. Mô hình này hỗ trợ đa ngôn ngữ và tạo embedding 384 chiều.

Văn bản đầu vào cho mỗi phim bao gồm:

- Tên phim
- Thể loại (genres)
- Mô tả nội dung (synopsis)

Hệ thống hỗ trợ hai loại index:

- IndexFlatL2: Tìm kiếm chính xác, phù hợp với dataset nhỏ-trung bình
 - + Độ phức tạp: $O(n)$ với n là số vector
 - + Không cần training
- IndexIVFFlat: Tìm kiếm xấp xỉ, phù hợp với dataset lớn
 - + Chia vector thành các cluster (default: $\min(100, n/10)$)
 - + Cần training trước khi sử dụng
 - + Nhanh hơn nhưng có thể bỏ sót kết quả

Khi người dùng nhập query (ví dụ: "phim về phép thuật và phiêu lưu"), hệ thống:

- Sinh embedding cho query
- Tìm K vector gần nhất theo khoảng cách L2
- Trả về danh sách phim tương ứng

5.6. Chia dữ liệu train/test

Hệ thống sử dụng phương pháp Stratified User-based Split thay vì random split thông thường. Với mỗi người dùng:

- 80% đánh giá đưa vào tập train
- 20% đánh giá đưa vào tập test

Điều này đảm bảo:

- Mọi người dùng trong test đều có trong train (không cold-start)
- Dữ liệu test phản ánh đúng hành vi thực tế
- Đánh giá công bằng cho tất cả người dùng

Người dùng có ít hơn min_ratings (default: 5) đánh giá sẽ có toàn bộ đánh giá đưa vào tập train để đảm bảo có đủ dữ liệu học.

6. ĐÁNH GIÁ MÔ HÌNH

6.1. Các phương pháp đánh giá

Hệ thống sử dụng 7 metrics đánh giá toàn diện:

- RMSE (Root Mean Squared Error): RMSE thấp hơn cho thấy mô hình dự đoán điểm số chính xác hơn. RMSE phạt nặng các sai số lớn do phép bình phương.
- MAE (Mean Absolute Error): MAE dễ hiểu hơn RMSE (đơn vị giống thang điểm gốc) và không phạt nặng outliers.
- Precision@K: Trong K phim được gợi ý, bao nhiêu phần trăm thực sự được người dùng đánh giá cao (≥ 7)?
- Recall@K: Trong số tất cả phim người dùng sẽ thích, mô hình tìm được bao nhiêu phần trăm?
- Coverage: Bao nhiêu phần trăm tổng số phim xuất hiện trong các gợi ý? Coverage thấp cho thấy mô hình có xu hướng chỉ gợi ý một số ít phim phổ biến.
- Diversity: Diversity cao cho thấy các gợi ý đa dạng, không lặp lại. Điều này quan trọng để người dùng khám phá nhiều loại phim khác nhau.

- Novelty: Novelty cao cho thấy mô hình gợi ý các phim ít phổ biến (long-tail items). Điều này giúp người dùng khám phá những viên ngọc ẩn.

6.2. Kết quả đánh giá

	RMSE	MAE	Precision@K	Recall@K	Coverage	Diversity	Novelty
User-Based	1.44	1.10	0.29	0.18	0.01	1	9.31
Item-Based	1.28	0.94	0.02	0.01	0.03	1	12.8
Neural CF	1.22	0.91	0.04	0.01	0.03	1	12.45
Hybrid	1.22	0.92	0.1	0.02	0.03	1	12.47

Sau khi huấn luyện và đánh giá, các mô hình được so sánh tổng thể để xác định:

- Mô hình có RMSE/MAE thấp nhất (dự đoán điểm chính xác nhất)
- Mô hình có Precision@K/Recall@K cao nhất (gợi ý chất lượng nhất)
- Mô hình có Coverage cao nhất (đa dạng nhất về catalog)

Các chỉ số này giúp lựa chọn mô hình phù hợp cho từng use case:

- RMSE/MAE quan trọng khi cần dự đoán điểm chính xác
- Precision@K quan trọng khi cần top-N gợi ý chất lượng
- Coverage/Novelty quan trọng khi muốn khuyến khích khám phá